

操作変数法 (IV)

内生性問題への対処

阿部景太

1. なぜ OLS では不十分か：内生性の問題
2. 操作変数法 (IV) のアイデア
3. 操作変数の 2 つの条件
4. 2 段階最小二乗法 (2SLS) の仕組み
5. 事例：教育の収益 (Card, 1995)
6. OLS と IV の比較と解釈
7. まとめ：因果推論ツールの全体像

内生性の問題

固定効果モデルでも解決できない問題

固定効果（FE）モデルは**時間不変の交絡変数**を除去できる。

しかし...

逆の因果関係（Reverse Causality）

- 原因 → 結果だけでなく
- 結果 → 原因という経路も存在する場合

例：警察官の数と犯罪件数

- 警察官を増やす → 犯罪が減る（と期待する）
- でも犯罪が多い地域ほど警察官を配置する → 相関が逆になる

具体例：教育の収益

$$\log(\text{賃金}_i) = \alpha + \beta \cdot \text{教育年数}_i + \varepsilon_i$$

直感：教育年数が長いほど賃金が高い $\rightarrow \beta > 0$ を期待。

問題：能力 (ability) という観察されない変数

$$\text{能力 (高)} \rightarrow \begin{cases} \text{教育年数 (長)} \\ \text{賃金 (高)} \end{cases}$$

能力が高い人 $\rightarrow$ 進学しやすいかつ賃金も高い

OLS で推定される β には能力の影響が混入してしまう。 $\rightarrow$ 欠落変数バイアス (OVB)

固定効果でも対処できない理由

固定効果モデル：

$$y_{it} = \alpha_i + \beta x_{it} + \varepsilon_{it}$$

「能力」は個人の時間不変の特性

→ 個人固定効果 α_i に吸収されるはずでは？

しかし：

- 個人レベルの**繰り返し観察データ**（個人パネルデータ）が必要
- 多くの場合、個人を長期間追跡したデータは入手困難
- 横断面データのみ → 固定効果で対処できない

別のアプローチが必要 → 操作変数法

操作変数法のアイデア

操作変数法のアイデア

内生変数（教育年数）の変動のうち、**外生的な変動だけを使って**係数を推定する。

外生的な変動とは？

- 能力などの観察されない要因とは**無関係**に生じる変動
- そのような変動を引き起こす変数 → **操作変数 (Instrument)**

良い操作変数のイメージ


- 「運」のような要因で生じる変動
- 本人の能力や努力とは無関係

Card (1995) : 大学の近さを操作変数に

操作変数：出身地の近くに 4 年制大学があるか (nearc4)

教育年数との関係		賃金との関係
大学が近い	通いやすい → 進学しやすい	教育を通じてのみ影響
大学が遠い	進学しにくい → 教育年数短い	直接の影響はない

「大学が近くにあるかどうか」という「運」を利用して、能力の影響を排除した上で教育の収益を推定する。



Card (1995) の場合

Z 大学の近さ

X 教育年数

Y 賃金

U 能力 (不観測)

U が観察できないため

OLS はバイアスを持つ

$Z \rightarrow X \rightarrow Y$ の経路のみを
使って β を推定する

操作変数の 2 つの条件

条件 1：関連性 (Relevance)

操作変数は内生変数と相関していなければならない。

$$\text{Cov}(z_i, x_i) \neq 0$$

Card (1995) の場合

- 大学が近い → 通いやすい → 教育年数が長い
- データで検証できる（第 1 段階回帰の F 統計量）

弱い操作変数 (Weak Instrument) の問題

操作変数と内生変数の相関が弱い場合、2SLS の推定値は不安定になる。

目安：第 1 段階の F 統計量 ≥ 10

条件 2：除外制約 (Exclusion Restriction)

操作変数は、**内生変数を通じてのみ**目的変数に影響する。

$$\text{Cov}(z_i, \varepsilon_i) = 0$$

Card (1995) の場合

大学への近さは、教育年数を通じてのみ賃金に影響し、それ以外の経路では賃金に影響しない。

重要：この条件はデータから直接検証できない。

経済学的な理論と常識的な判断に基づいて主張する必要がある。

2 段階最小二乗法 (2SLS)

名前の通り、2 段階に分けて推定する。

第 1 段階 (First Stage)

内生変数を操作変数に回帰し、外生的な変動分（予測値）を取り出す。

$$x_i = \pi_0 + \pi_1 z_i + \eta_i \quad \Rightarrow \quad \hat{x}_i = \hat{\pi}_0 + \hat{\pi}_1 z_i$$

第 2 段階 (Second Stage)

予測値 $\hat{x}_i$ を内生変数の代わりに使って、目的変数に回帰する。

$$y_i = \alpha + \beta \hat{x}_i + \varepsilon_i$$

$\hat{x}_i$ は能力と無関係な外生的変動のみを含む → バイアスが除去される

事例：教育の収益

データの確認

Card (1995) のデータは wooldridge パッケージに含まれる。

```
##      wage educ nearc4 exper black smsa
## 1   548     7      0     16     1     1
## 2   481    12      0      9     0     1
## 3   721    12      0     16     0     1
## 4   250    11      1     10     0     1
## 5   729    12      1     16     0     1
## 6   500    12      1      8     0     1
```

変数	内容
wage	時間当たり賃金 (セント)
educ	教育年数
nearc4	4 年制大学が近くにある場合 1

第 1 段階：操作変数の妥当性確認

条件 1 (関連性) の検証：大学への近さ → 教育年数

```
first_stage <- feols(educ ~ nearc4 + exper + black + smsa,  
                     data = card)  
etable(first_stage)
```

```
##                               first_stage  
## Dependent Var.:                educ  
##  
## Constant           16.46*** (0.1136)  
## nearc4              0.3850*** (0.0816)  
## exper              -0.3970*** (0.0087)  
## black              -1.114*** (0.0849)  
## smsa               0.4380*** (0.0845)  
##
```

第 1 段階の F 統計量

```
fitstat(first_stage, "f")
```

```
## F-test: stat = 671.79, p < 2.2e-16, on 4 and 3,005 DoF.
```

- `nearc4` の係数が正で有意 → 大学に近いほど教育年数が長い
- F 統計量 ≥ 10 → 弱い操作変数の問題なし

条件 1 (関連性) が満たされていることを確認。

OLS 推定 (比較用)

まず、通常の OLS で教育の収益を推定する。

```
reg_ols <- feols(log(wage) ~ educ + exper + black + smsa,  
                 data = card)  
etable(reg_ols)
```

```
##                                reg_ols  
## Dependent Var.:              log(wage)  
##  
## Constant                4.823*** (0.0629)  
## educ                    0.0762*** (0.0036)  
## exper                   0.0396*** (0.0022)  
## black                   -0.2348*** (0.0171)  
## smsa                    0.1867*** (0.0157)  
##
```

IV 推定 (2SLS)

`feols()` では | の後に 内生変数 ~ 操作変数を指定する。

```
reg_iv <- feols(log(wage) ~ exper + black + smsa | educ ~ nearc4,  
               data = card)  
etable(reg_iv)
```

```
##                                reg_iv  
## Dependent Var.:                log(wage)  
##  
## Constant                      3.121*** (0.7810)  
## educ                          0.1785*** (0.0469)  
## exper                         0.0802*** (0.0187)  
## black                        -0.1182*  (0.0567)  
## smsa                         0.1277*** (0.0323)  
##
```

OLS と IV の比較

```
##                                reg_ols                                reg_iv
##                                OLS IV (大学距離)
## Dependent Var.:              log(wage)              log(wage)
##
## Constant          4.823*** (0.0629)   3.121*** (0.7810)
## educ              0.0762*** (0.0036)  0.1785*** (0.0469)
## exper             0.0396*** (0.0022)  0.0802*** (0.0187)
## black            -0.2348*** (0.0171)  -0.1182*  (0.0567)
## smsa              0.1867*** (0.0157)  0.1277*** (0.0323)
## -----
## S.E. type          IID                  IID
## Observations       3,010                3,010
## R2                  0.26152              0.15376
## Adj. R2             0.26054              0.15264
```

手法	教育年数 1 年の効果	解釈
OLS	約 +7.6%	能力バイアス含む
IV	約 +17.9%	外生的な変動のみ使用

なぜ IV の推定値が OLS より大きいのか？

1. **測定誤差バイアス**：教育年数は記憶に頼るため誤差が生じる。誤差があると OLS は真の値より小さく推定される（減衰バイアス）。
2. **局所平均処置効果（LATE）**：IV は大学の近さによって進学行動が変わった人々（compliers）に対する効果を推定する。このグループの教育の収益が平均より高い可能性がある。

まとめ

IV の強み

- 逆の因果関係・欠落変数バイアスに対処できる
- 観察データから因果効果を推定できる

前提条件（仮定）

- 条件 1（関連性）：第 1 段階の F 統計量で確認可能
- 条件 2（除外制約）：**データでは検証できない** → 理論的に正当化

IV の限界

- 良い操作変数を見つけることが難しい
- LATE を推定する（局所的な効果）
- 弱い操作変数の場合、推定値が不安定になる

手法	解決する問題	必要な条件
固定効果 (FE)	時間不変の交絡変数	パネルデータ
差の差法 (DiD)	共通トレンドを除いた処置効果	平行トレンドの仮定
回帰不連続 (RDD)	閾値近傍での局所的な処置効果	閾値付近の連続性
操作変数法 (IV)	内生性・逆の因果関係	関連性+除外制約

これらの手法を組み合わせることで、観察データから因果効果を推定するための基本的な分析ツールが揃う。

本章の R コード：まとめ

```
pacman::p_load(tidyverse, fixest, wooldridge)
data(card)
```

第 1 段階：操作変数の関連性を確認

```
first_stage <- feols(educ ~ nearc4 + exper + black + smsa,
                     data = card)
fitstat(first_stage, "f") # F 統計量を確認
```

OLS 推定

```
reg_ols <- feols(log(wage) ~ educ + exper + black + smsa,
                 data = card)
```

IV 推定 (2SLS)

```
reg_iv <- feols(log(wage) ~ exper + black + smsa | educ ~ nearc4,
```